Actividad 4 - Pruebas realizadas

Métodos de aprendizaje no supervisado - Clustering jerárquico aglomerativo

Objetivo de las pruebas

Validar que el componente no supervisado identifique perfiles de comportamiento ferroviario sin utilizar una variable objetivo. Cada observación del clustering representa un **perfil por tren** con indicadores históricos de puntualidad y retraso. El único método de agrupamiento utilizado es **clustering jerárquico aglomerativo con enlace Ward**.

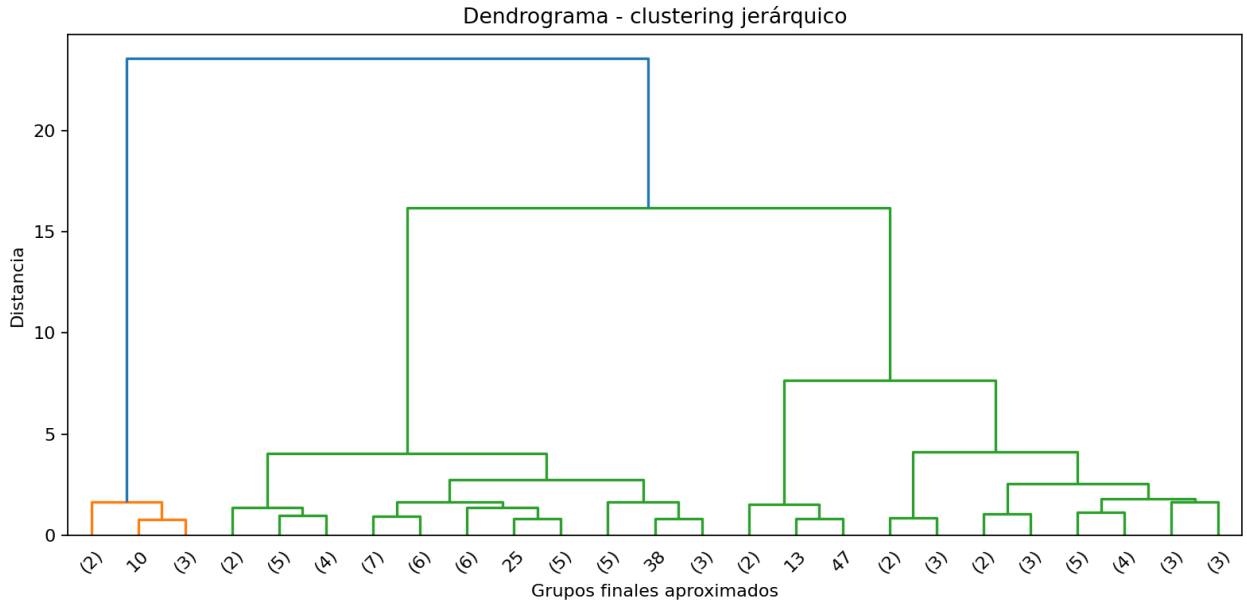
La ejecución documentada trabajó con 80 perfiles de tren y seis variables: retraso mediano, retraso promedio, percentil 90 del retraso, desviación del retraso, porcentaje a tiempo y porcentaje de retrasos severos.

Resultados generales de la ejecución

Indicador	Resultado
Trenes analizados	80
Variables utilizadas	6
Método de clustering	Aglomerativo - Ward
Número de clusters seleccionado	2
Silhouette para k = 2	0,7118
Distribución de clusters	74 trenes / 6 trenes

1. Dendrograma del clustering jerárquico

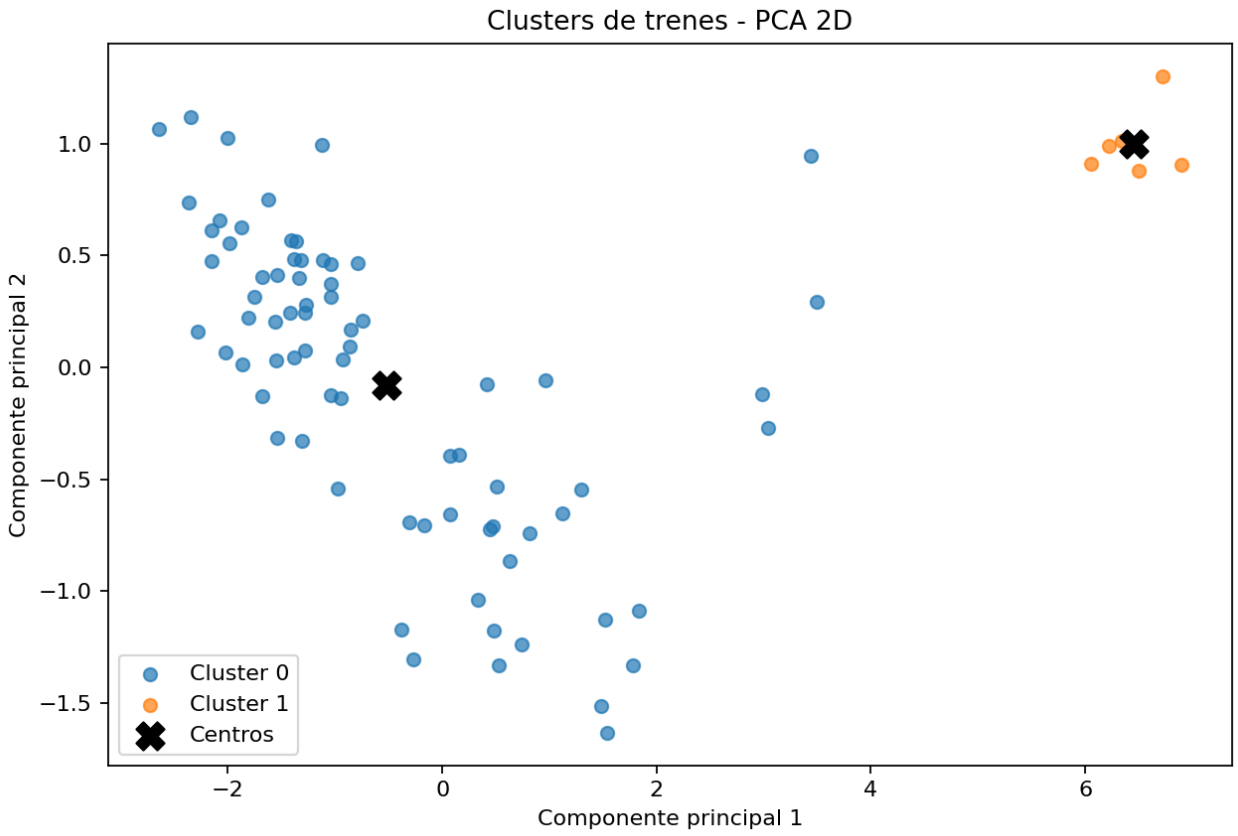
El dendrograma representa cómo los perfiles de tren se van agrupando de forma jerárquica según su similitud. Las uniones a mayor altura indican grupos más diferentes. Esta evidencia permite inspeccionar la estructura de los datos antes de fijar el número final de clusters.



La selección final se contrastó con silhouette para k entre 2 y 6. El mejor valor fue **0,7118 con k = 2**, superior a las alternativas evaluadas.

2. Visualización de clusters en dos dimensiones

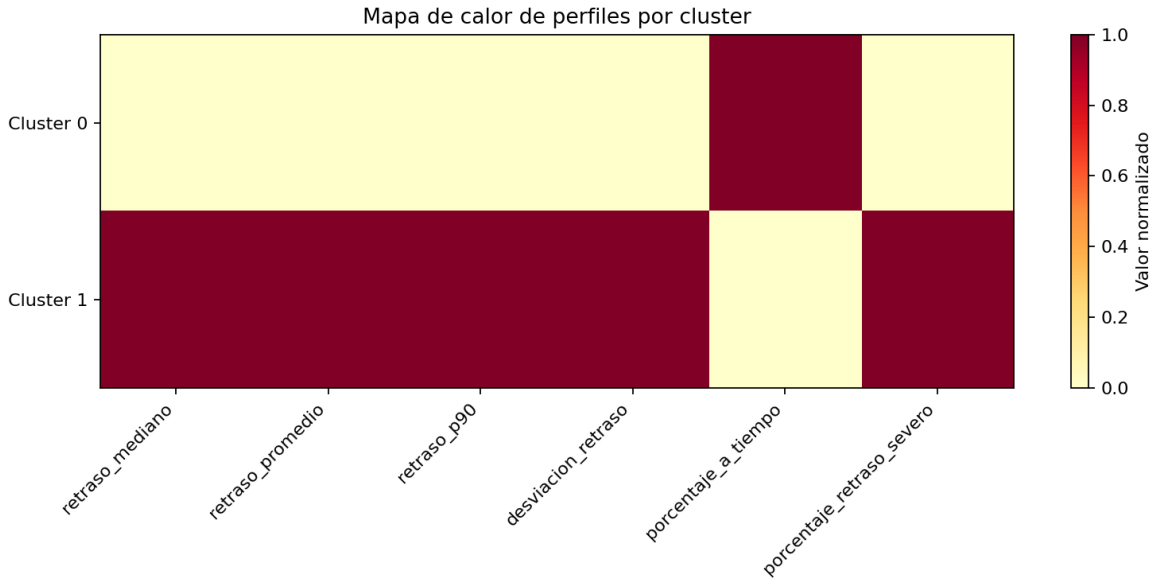
El clustering se ejecuta sobre las seis variables escaladas. Para visualizar el resultado en un plano, se usa PCA únicamente como técnica de reducción visual a dos componentes; **PCA no crea los clusters**. Los puntos conservan la etiqueta obtenida por el clustering jerárquico.



La proyección muestra una separación clara entre el grupo mayoritario y un grupo pequeño con un perfil de retrasos considerablemente más alto. Los marcadores negros representan los centros visuales de cada grupo en el plano PCA.

3. Perfil promedio de los clusters

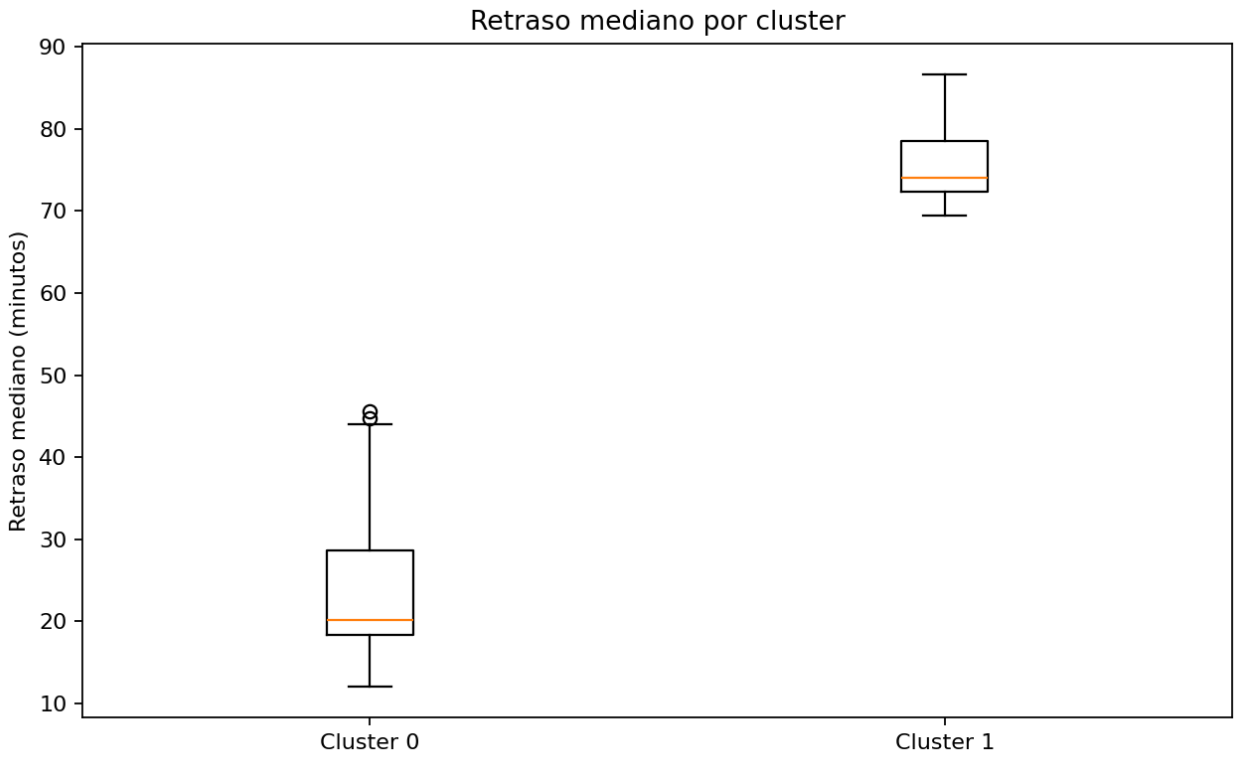
El mapa de calor compara los promedios normalizados de las variables de cada cluster. El **Cluster 0** reúne 74 trenes con comportamiento relativamente más favorable, mientras que el **Cluster 1** reúne 6 trenes con valores altos de retraso y retraso severo. En la ejecución, el retraso mediano promedio fue 23,76 minutos para el Cluster 0 y 76,01 minutos para el Cluster 1.



La diferencia entre perfiles también se refleja en el porcentaje de retraso severo: 30,35 % en el Cluster 0 frente a 97,56 % en el Cluster 1 para la ejecución documentada.

4. Distribución del retraso mediano por cluster

El boxplot permite comparar la distribución del retraso mediano dentro de cada grupo. La separación entre las cajas confirma que los clusters representan perfiles distintos y no una división puramente visual. El Cluster 1 concentra trenes con retrasos medianos mucho mayores que el Cluster 0.



Esta evidencia complementa el dendrograma, el silhouette y el mapa de calor mostrando que la diferencia entre grupos se conserva en una variable operacional interpretable: el retraso mediano.

Resumen de pruebas automáticas

El notebook incorpora pruebas automáticas para validar el número de registros, el método empleado, la preparación de datos, la asignación de clusters y la generación de las evidencias gráficas.

Prueba	Estado	Validación
Hay trenes suficientes para agrupar	OK	Valida que existen perfiles suficientes para el número de grupos.
Se usó un único método no supervisado	OK	Confirma el uso de AgglomerativeClustering.
No se usa variable objetivo supervisada	OK	Verifica que is_delayed no participa en las variables.
La matriz escalada no tiene nulos	OK	Comprueba que la entrada al clustering está completa.
El número de clusters es mayor que uno	OK	Valida una partición real de los perfiles.
Cada tren tiene cluster asignado	OK	Confirma que todos los perfiles recibieron etiqueta.
El silhouette fue calculado	OK	Valida la comparación cuantitativa de k.
El PCA tiene dos componentes	OK	Comprueba la proyección utilizada para visualizar.
El heatmap fue generado	OK	Verifica la evidencia de perfiles promedio.
La gráfica PCA fue generada	OK	Verifica la evidencia de separación visual.
El dendrograma fue generado	OK	Verifica la evidencia del proceso jerárquico.

Resultado general: 11/11 pruebas aprobadas.

Conclusión: las pruebas confirman que el flujo no supervisado construye perfiles por tren, prepara las variables sin una etiqueta supervisada, aplica un único clustering jerárquico aglomerativo y produce grupos interpretables mediante dendrograma, silhouette, proyección PCA, mapa de calor y boxplot.